

# Exercices

## Exercice 1

**Taille des classes et zones défavorisées.** L'État met en place un programme de réduction de la taille des classes en CP et évalue son efficacité à travers un test passé à la fin de l'année scolaire. Le programme cible spécifiquement les zones défavorisées. Un estimateur naïf, qui comparerait directement les résultats des élèves bénéficiaires de ce programme avec ceux des non-bénéficiaires, conduirait-il à sous-estimer ou surestimer l'effet du traitement sur les élèves traités ?

**Adoption des médias sociaux et santé mentale.** Supposons que nous étudions l'effet de l'usage des médias sociaux sur la santé mentale des adolescents. La variable d'intérêt ici est la probabilité de souffrir de troubles de santé mentale. Un estimateur naïf, qui comparerait directement les problèmes de santé mentale des adolescents utilisateurs de médias sociaux avec la prévalence de ces problèmes chez les non-utilisateurs, conduirait-il à sous-estimer ou à surestimer l'effet potentiellement néfaste des médias sociaux sur la santé mentale des utilisateurs ?

**Étude et salaire.** On veut savoir si terminer les études supérieures augmente le salaire gagné. Peut-on comparer les salaires de ceux qui terminent les études supérieures versus les salaires de ceux qui ne les terminent pas ? Pourquoi ?

**Adoption des modèles de LLM et productivité horaire des entreprises.** On s'intéresse à la population des entreprises, comptant entre 5 et 20 salariés, dans le secteur de l'IT français. Vous observez la productivité horaire de ces entreprises en 2024 et le fait qu'elles aient adopté ou non des modèles de LLM dans leur processus de production. Vous considérez l'estimateur suivant :

$$\hat{\Delta} = \frac{1}{N_1} \sum_{i/T_i=1} Y_i - \frac{1}{N_0} \sum_{i/T_i=0} Y_i$$

avec  $N_1$  le nombre d'entreprises traitées et  $N_0$  le nombre d'entreprises non traitées dans l'échantillon,  $N = N_0 + N_1$  désignant la taille de l'échantillon (supposé représentatif de la population considérée).

Vos recherches sur le sujet vous amènent à la conclusion suivante : en 2020, la productivité horaire ne dépendait pas de la taille des entreprises. Toutefois, les entreprises de taille plus petite semblaient être plus susceptibles de tirer parti

de l'adoption de ces modèles, en raison de leur plus grande flexibilité et de leur capacité à intégrer plus facilement ces outils dans leurs processus.

1. Quel paramètre l'estimateur  $\hat{\Delta}$  permet-il d'identifier ?
2. Sous quelle condition cet estimateur constitue-t-il un bon estimateur de l'Average Treatment Effect on the Treated ? Cette condition vous semble-t-elle plausible dans ce contexte ?
3. Cet estimateur est-il également un bon estimateur de l'Average Treatment Effect ? Si ce n'est pas le cas, conduit-il à surestimer ou à sous-estimer cet effet ?

## Exercice 2

**Biais de sélection, hétérogénéité et régression linéaire.** Vous disposez de trois bases de données. Dans chacune d'elles, vous observez  $Y_0$ , le revenu potentiel sans traitement,  $Y_1$ , le revenu potentiel avec traitement,  $Y$ , le revenu observé par le statisticien, une variable  $X$ , ainsi que la variable de traitement  $T$  avec 1 si l'individu est traité et 0 sinon.

1. Dans le cadre du modèle de Rubin, quelle est la différence entre  $Y_0$ ,  $Y_1$  et  $Y$  ?

À partir de chacune des trois bases de données, répondre aux questions suivantes :

2. Calculer l'effet moyen du traitement (ATE). Calculer l'effet moyen du traitement sur les traités (ATT).
3. Est-il plausible de croire que ces données proviennent d'une expérience randomisée ? Justifier votre réponse.
4. Une autre quantité d'intérêt est la différence entre la moyenne de  $Y$  pour les individus ayant reçu le traitement et la moyenne de  $Y$  pour ceux ne l'ayant pas reçu. Calculer cette valeur.
5. Est-il plausible de croire que l'assignation au traitement est indépendante conditionnellement à  $X$  ? Justifier votre réponse.
6. Sélectionner aléatoirement 10% de l'échantillon et estimer le coefficient associé à  $T$  dans une régression de  $Y$  sur  $T$ , puis dans une régression de  $Y$  sur  $T$  et  $X$ . Discuter les résultats.